KOMPARASI ALGORITMA PEMBELAJARAN MESIN KLASIFIKASI UNTUK CUSTOMER CHURN IN TELECOMMUNICATIONS

Semester Genap Tahun Akademik 2025/2026

(Revisi)

Kelompok 5
Andree Hayden Fernando (00000112246) - Project Lead
Frans Marco Haryanto (00000108659) - Model Developer
Kenzie Tristan Tang (00000110240) - Presenter
Kingsty James Wayne (00000110615) - Data Analyst

Program Studi Sistem Informasi
Fakultas Teknik dan Informatika
Universitas Multimedia Nusantara

2026

BAB 1: PENDAHULUAN

1.1 Latar Belakang

Industri telekomunikasi merupakan salah satu sektor yang mengalami perkembangan sangat pesat, terutama dengan meningkatnya penetrasi internet yang mencapai 79,5% dari total populasi di Indonesia pada tahun 2024[1,2]. Namun, pertumbuhan ini juga memicu persaingan yang sangat ketat antar penyedia layanan, di mana pelanggan memiliki kebebasan besar untuk berpindah dari satu provider ke kompetitor lain dengan relatif mudah[2,3]. Fenomena perpindahan atau penghentian layanan oleh pelanggan ini dikenal sebagai **customer churn**[4,5].

Tingginya tingkat churn menjadi tantangan krusial bagi keberlanjutan bisnis karena berdampak langsung pada penurunan pendapatan, pengurangan pangsa pasar, dan degradasi reputasi merek[5]. Secara ekonomi, mempertahankan pelanggan yang sudah ada jauh lebih menguntungkan karena biaya untuk menarik pelanggan baru diperkirakan mencapai lima kali lipat lebih besar dibandingkan biaya retensi[5]. Oleh karena itu, perusahaan telekomunikasi perlu mengambil langkah proaktif dengan memberikan insentif retensi atau paket layanan yang menarik bagi pelanggan yang berisiko[2].

Melalui pendekatan **machine learning**, perusahaan dapat mengidentifikasi pola perilaku pelanggan secara dini untuk memprediksi risiko churn dengan tingkat akurasi yang lebih tinggi dibandingkan metode tradisional[1,4]. Berbagai algoritma klasifikasi seperti *Random Forest*, *XGBoost*, dan *Decision Tree* telah terbukti efektif dalam menangani dataset besar dan variabel yang kompleks dalam industri ini[6]. Namun, nilai sebuah model tidak hanya ditentukan oleh pemilihan algoritma, tetapi juga oleh protokol evaluasi yang benar. Kesalahan urutan pra-pemrosesan, misalnya menerapkan teknik *oversampling* sebelum pembagian data, dapat menyebabkan kebocoran data (*data leakage*) sehingga performa model terlihat jauh lebih baik daripada kenyataannya.

Proyek ini bertujuan untuk melakukan komparasi sistematis terhadap enam algoritma pembelajaran mesin dan satu model *baseline* dengan protokol evaluasi yang bebas kebocoran data, serta menerjemahkan hasil model menjadi wawasan dan simulasi yang dapat langsung mendukung strategi retensi perusahaan.

1.2 Rumusan Masalah

Berdasarkan konteks yang telah dijelaskan, rumusan masalah dalam penelitian ini adalah:

1. Faktor-faktor apa saja yang memberikan pengaruh paling signifikan terhadap keputusan pelanggan untuk melakukan churn di sektor telekomunikasi?
2. Bagaimana performa komparatif algoritma *Logistic Regression*, *Decision Tree*, *Random Forest*, *XGBoost*, *LightGBM*, dan *CatBoost* dalam mengklasifikasikan status churn pelanggan?
3. Strategi penanganan ketidakseimbangan kelas manakah (tanpa penanganan, *class weighting*, atau SMOTE) yang paling efektif, dan seberapa besar dampak optimasi *hyperparameter* terhadap performa model?

4. Bagaimana hasil prediksi model dapat diterjemahkan menjadi strategi retensi yang bernilai bagi bisnis?

1.3 Tujuan Penelitian

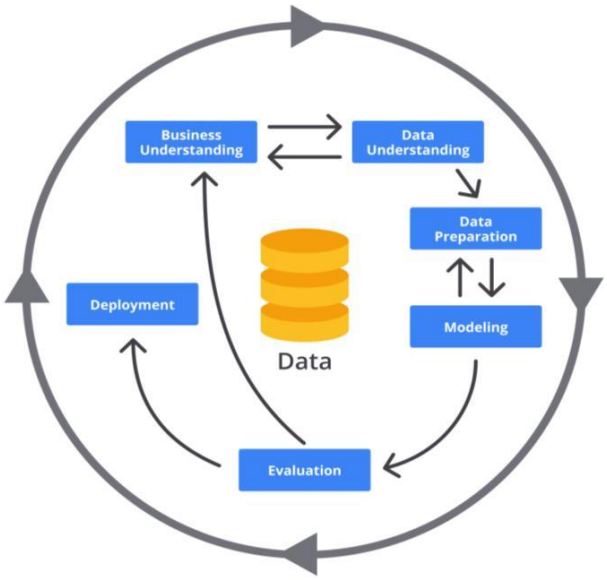
Tujuan yang ingin dicapai melalui pelaksanaan proyek ini adalah:

1. Melakukan eksplorasi data (*Exploratory Data Analysis*) secara mendalam pada dataset churn guna memahami karakteristik dasar dan isu ketidakseimbangan kelas.
2. Membangun dan membandingkan 18 konfigurasi model (6 algoritma dan 1 *baseline* dengan 3 strategi penanganan *imbalance*) menggunakan *5-fold stratified cross-validation* dan *pipeline* yang mencegah kebocoran data.
3. Mengevaluasi model terbaik pada data uji yang mempertahankan distribusi kelas asli menggunakan metrik PR-AUC, ROC-AUC, *precision*, *recall*, dan F1-score, serta menentukan *threshold* keputusan yang optimal.
4. Mengidentifikasi faktor pendorong churn menggunakan SHAP dan menerjemahkan hasil model ke dalam simulasi serta rekomendasi bisnis.

BAB 2: LITERATURE REVIEW

2.1 CRISP-DM Framework

Proyek ini mengikuti metodologi **CRISP-DM (Cross-Industry Standard Process for Data Mining)**, yaitu kerangka kerja standar industri yang terdiri dari enam fase berurutan namun iteratif. CRISP-DM dipilih karena sifatnya yang fleksibel, terbukti di industri, dan menyeluruh dalam mencakup seluruh siklus hidup proyek data mining[7].



Gambar 1. CRISP-DM Framework

2.2 Decision Tree

Decision Tree merupakan model prediksi yang bersifat *supervised* dan berfungsi untuk menggantikan pengalaman manusia dalam proses pengambilan keputusan[8]. Algoritma ini, khususnya varian C4.5 yang dikembangkan oleh Ross Quinlan, bekerja dengan membagi dataset secara rekursif berdasarkan atribut yang memiliki *Information Gain* paling tinggi atau yang paling informatif[5]. Keunggulan utama Decision Tree adalah hasil keputusannya yang mudah diinterpretasikan oleh pemangku kepentingan, namun algoritma ini cenderung rentan terhadap masalah *overfitting* jika pohon dibiarkan tumbuh terlalu kompleks (Fauzan et al., 2025).

2.3 Random Forest

Random Forest adalah metode *ensemble learning* yang mengintegrasikan metodologi agregasi *bootstrap* dengan konsep pohon keputusan[9]. Algoritma ini membangun sekumpulan pohon keputusan secara independen dan menghasilkan prediksi akhir berdasarkan mekanisme suara terbanyak (*voting*) dari setiap pohon tersebut[4]. Dengan menggabungkan banyak pohon, Random Forest mampu meningkatkan stabilitas, akurasi prediksi, serta lebih tangguh terhadap variabilitas data (*noise*) dibandingkan dengan pohon keputusan tunggal[4,8].

2.4 Logistic Regression

Logistic Regression merupakan teknik statistik dan pembelajaran mesin yang digunakan untuk memodelkan hubungan antara satu variabel dependen biner (seperti Churn atau No Churn)

dengan satu atau lebih variabel independen[10]. Meskipun merupakan algoritma dasar, Logistic Regression sangat efektif dalam mengestimasi probabilitas kejadian suatu peristiwa dengan menyesuaikan persamaan linear pada data yang diamati. Algoritma ini sering digunakan sebagai model *baseline* karena kesederhanaannya dan kemampuannya dalam memberikan interpretasi koefisien fitur yang baik[10].

2.5 XGBoost & LightGBM

Extreme Gradient Boosting (XGBoost) adalah algoritma berbasis *gradient boosting* yang bekerja secara iteratif, di mana setiap pohon keputusan baru dibangun untuk memperbaiki kesalahan dari pohon sebelumnya (Gusti Ayu et al., 2025). XGBoost dikenal karena efisiensinya dalam pemrosesan data besar dan fitur-fitur seperti regularisasi untuk menghindari *overfitting*[4]. Sementara itu, LightGBM merupakan varian *gradient boosting* generasi baru yang dirancang untuk efisiensi memori yang lebih baik dan mampu menangani fitur dengan distribusi kompleks pada data tabular[12].

2.6 CatBoost

CatBoost (*Categorical Boosting*) adalah algoritma *gradient boosting* yang dirancang khusus untuk menangani fitur kategorikal secara langsung[17]. Alih-alih menggunakan *one-hot encoding*, CatBoost mengubah nilai kategori menjadi statistik numerik berbasis target menggunakan skema *ordered target statistics*, dan melatih pohon dengan *ordered boosting* untuk mencegah pergeseran prediksi (*prediction shift*) akibat kebocoran informasi target[17]. Karakteristik ini membuat CatBoost relevan untuk dataset dengan proporsi fitur kategorikal yang tinggi.

2.7 Penanganan Imbalanced Data

Ketidakseimbangan kelas (*class imbalance*) terjadi ketika jumlah sampel pada satu kelas jauh lebih banyak dibandingkan kelas lainnya, yang dapat menyebabkan model cenderung bias terhadap kelas mayoritas[10]. *Synthetic Minority Over-sampling Technique* (SMOTE) adalah teknik untuk mengatasi masalah ini dengan cara membuat sampel sintetis baru melalui interpolasi antara sampel kelas minoritas yang berdekatan[18]. Penerapan SMOTE dilaporkan dapat meningkatkan nilai *recall* dalam menangkap kasus positif pada dataset yang tidak seimbang[10].

Hal yang perlu diperhatikan adalah SMOTE hanya boleh diterapkan pada **data latih setelah pembagian data**. Jika SMOTE diterapkan sebelum pembagian, sampel sintetis yang dibentuk dari data latih dapat masuk ke data uji (dan sebaliknya), serta data uji tidak lagi mencerminkan distribusi kelas di dunia nyata. Kondisi ini menyebabkan kebocoran data dan hasil evaluasi yang terlalu optimis. Alternatif lain yang tidak membuat data baru adalah **class weighting**, yaitu memberikan bobot kesalahan yang lebih besar pada kelas minoritas selama pelatihan.

2.8 Optimasi Hyperparameter

Grid Search Cross-Validation (GridSearchCV) adalah pendekatan sistematis untuk menentukan kombinasi *hyperparameter* terbaik dengan menguji setiap kombinasi parameter yang telah ditentukan menggunakan *k-fold cross-validation*[5]. Kelemahannya, jumlah kombinasi meningkat secara eksponensial seiring bertambahnya parameter. *Randomized*

Search (RandomizedSearchCV) hanya mencoba sejumlah kombinasi yang diambil secara acak dari ruang parameter. Bergstra dan Bengio[19] menunjukkan bahwa pencarian acak umumnya lebih efisien daripada *grid search* karena hanya sebagian kecil *hyperparameter* yang benar-benar berpengaruh terhadap performa model.

2.9 Metrik Evaluasi untuk Data Tidak Seimbang

Pada data tidak seimbang, *accuracy* dapat menyesatkan. Dengan proporsi churn 22,5%, model yang selalu memprediksi "No Churn" sudah memperoleh *accuracy* 77,5% tanpa menangkap satu pun pelanggan churn. Oleh karena itu, penelitian ini menggunakan **PR-AUC** (*Area Under the Precision-Recall Curve*, dihitung sebagai *average precision*) sebagai metrik utama. Saito dan Rehmsmeier[20] menunjukkan bahwa kurva *precision-recall* lebih informatif dibanding kurva ROC untuk mengevaluasi klasifikasi biner pada data tidak seimbang. Nilai PR-AUC model acak sama dengan proporsi kelas positif, sehingga mudah dijadikan pembanding.

2.10 SHAP (Shapley Additive Explanations)

SHAP adalah metode interpretasi model berbasis teori permainan (*Shapley values*) yang mengukur kontribusi setiap fitur terhadap prediksi individual[21]. Nilai SHAP positif berarti fitur tersebut menaikkan probabilitas prediksi kelas positif (churn), sedangkan nilai negatif menurunkannya. Dengan merata-ratakan nilai absolut SHAP, diperoleh tingkat kepentingan global setiap fitur.

2.11 Gap Research

Berdasarkan tinjauan pustaka, banyak penelitian sebelumnya mengenai customer churn hanya berfokus pada perbandingan satu atau dua algoritma tanpa melakukan pencarian parameter yang mendalam[5,9]. Selain itu, masih terbatas studi yang membandingkan beberapa strategi penanganan ketidakseimbangan kelas secara sistematis pada dataset telekomunikasi berskala besar[5,12], dan evaluasi umumnya berhenti pada metrik akurasi tanpa menerjemahkan hasil model ke dalam dampak bisnis. Penelitian ini mengisi celah tersebut dengan membandingkan enam algoritma dan tiga strategi penanganan *imbalance* dalam *pipeline* yang bebas kebocoran data, menggunakan metrik yang sesuai untuk data tidak seimbang, serta melengkapinya dengan interpretasi SHAP dan simulasi dampak bisnis.

BAB 3: METODOLOGI

Penelitian ini mengikuti kerangka kerja CRISP-DM (*Cross-Industry Standard Process for Data Mining*), yang merupakan standar industri untuk proyek penambangan data yang terdiri dari enam fase iteratif: pemahaman bisnis, pemahaman data, persiapan data, pemodelan, evaluasi, dan penyebaran[13].

3.1 Business Understanding

Fase awal ini berfokus pada pemahaman tujuan bisnis telekomunikasi, yaitu retensi pelanggan. Masalah utama yang dihadapi adalah tingginya tingkat churn yang menyebabkan kerugian finansial signifikan[4]. Proyek ini bertujuan membangun model prediktif yang mampu mengidentifikasi pelanggan berisiko tinggi sehingga manajemen dapat mengambil langkah preventif secara proaktif, seperti pemberian insentif khusus[14]. Karena anggaran retensi terbatas, keluaran model berupa **skor risiko** yang dapat digunakan untuk memprioritaskan pelanggan yang dihubungi.

3.2 Data Understanding

Sebelum melakukan analisis mendalam, langkah awal adalah memahami struktur dan kondisi dasar dataset:

- Ukuran dataset: 594.194 baris × 21 kolom (setelah kolom *id* dihapus: 19 fitur dan 1 target).
- Tipe data: 4 kolom numerik (SeniorCitizen, tenure, MonthlyCharges, TotalCharges) dan 15 kolom kategorikal, ditambah kolom target Churn. Pada tahap pemodelan, SeniorCitizen (bernilai 0/1) diperlakukan sebagai fitur kategorikal sehingga terdapat 3 fitur numerik dan 16 fitur kategorikal.
- Missing values: Tidak ada missing value pada seluruh kolom.
- Data duplikat: Tidak ditemukan data duplikat. Pemeriksaan dilakukan tanpa menyertakan kolom *id*, karena kolom *id* selalu unik sehingga akan menyembunyikan baris yang sebenarnya identik.

3.2.1 Statistik Deskriptif

Berdasarkan analisis statistik pada fitur numerik utama:

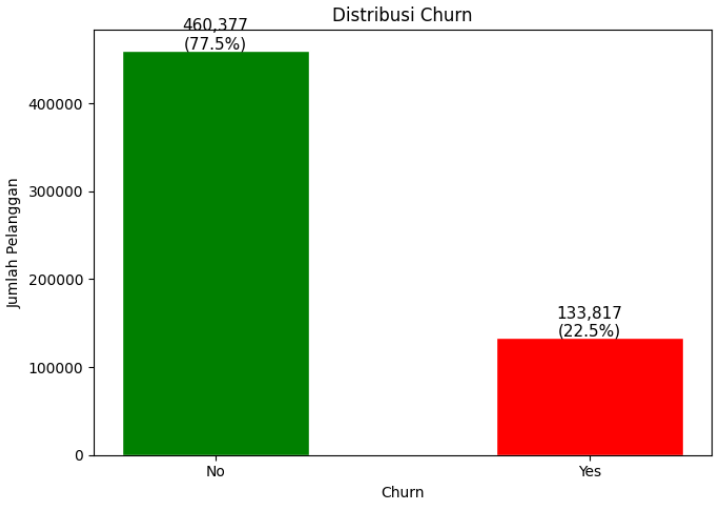
- Tenure: Rata-rata pelanggan telah berlangganan selama 36,6 bulan dengan variasi yang sangat tinggi (Std: 25 bulan), menunjukkan populasi pelanggan yang beragam dari pelanggan baru hingga sangat loyal.
- MonthlyCharges: Tagihan bulanan rata-rata sebesar 65,87 unit mata uang dengan median 74,10. Median yang lebih besar dari rata-rata menunjukkan distribusi cenderung *left-skewed*.
- TotalCharges: Rata-rata total tagihan mencapai 2.494,37 unit mata uang.
- SeniorCitizen: Hanya sekitar 11,4% pelanggan yang merupakan kategori lansia.

3.2.2 Pengecekan Outlier

Deteksi pencilan dilakukan menggunakan metode *Interquartile Range* (IQR). Hasilnya menunjukkan tidak adanya outlier ekstrem pada fitur tenure, MonthlyCharges, maupun TotalCharges, sehingga tidak diperlukan penanganan khusus sebelum pemodelan.

3.2.3 Distribusi Churn (Target)

Variabel target menunjukkan adanya ketidakseimbangan kelas (*class imbalance*): No Churn sebanyak 460.377 data (77,5%) dan Churn sebanyak 133.817 data (22,5%). Kondisi ini memerlukan perhatian khusus. Penelitian ini membandingkan tiga strategi penanganan (lihat Subbab 3.4) dan menggunakan metrik yang sesuai untuk data tidak seimbang.



Gambar 2. Distribusi Variabel Target (Churn)

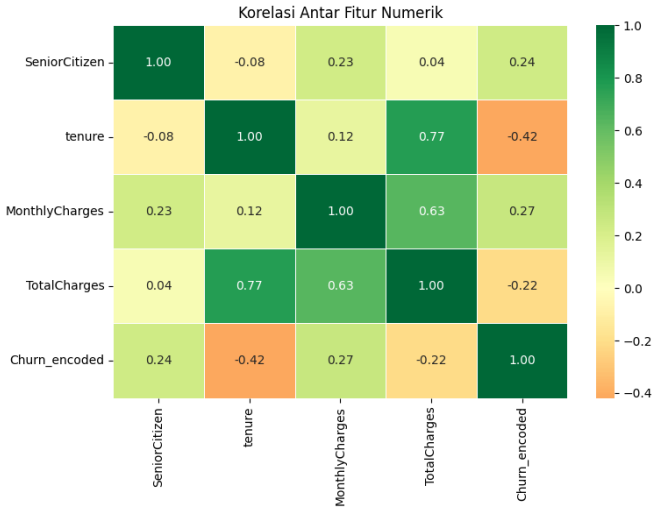
3.2.4 Distribusi Tenure dan Uji Normalitas

Distribusi tenure bersifat bimodal dengan dua puncak signifikan, yaitu pada pelanggan baru (0–10 bulan) dan pelanggan sangat loyal (60–72 bulan)[6]. Uji Shapiro-Wilk pada sampel 5.000 data mengonfirmasi bahwa tenure, MonthlyCharges, dan TotalCharges tidak berdistribusi normal ($p < 0,05$). Hal ini mendukung penggunaan algoritma non-parametrik berbasis pohon yang tidak mensyaratkan asumsi normalitas.

3.2.5 Matriks Korelasi

Analisis menggunakan heatmap korelasi Pearson menunjukkan:

- Tenure & TotalCharges ($r \approx 0,83$): Korelasi positif yang sangat kuat, sehingga perlu diwaspadai multikolinearitas pada model linear.
- Tenure & Churn ($r \approx -0,35$): Semakin lama masa berlangganan, semakin kecil risiko pelanggan untuk berhenti.
- MonthlyCharges & Churn ($r \approx 0,19$): Pelanggan dengan tagihan bulanan lebih tinggi memiliki risiko churn yang sedikit lebih besar.

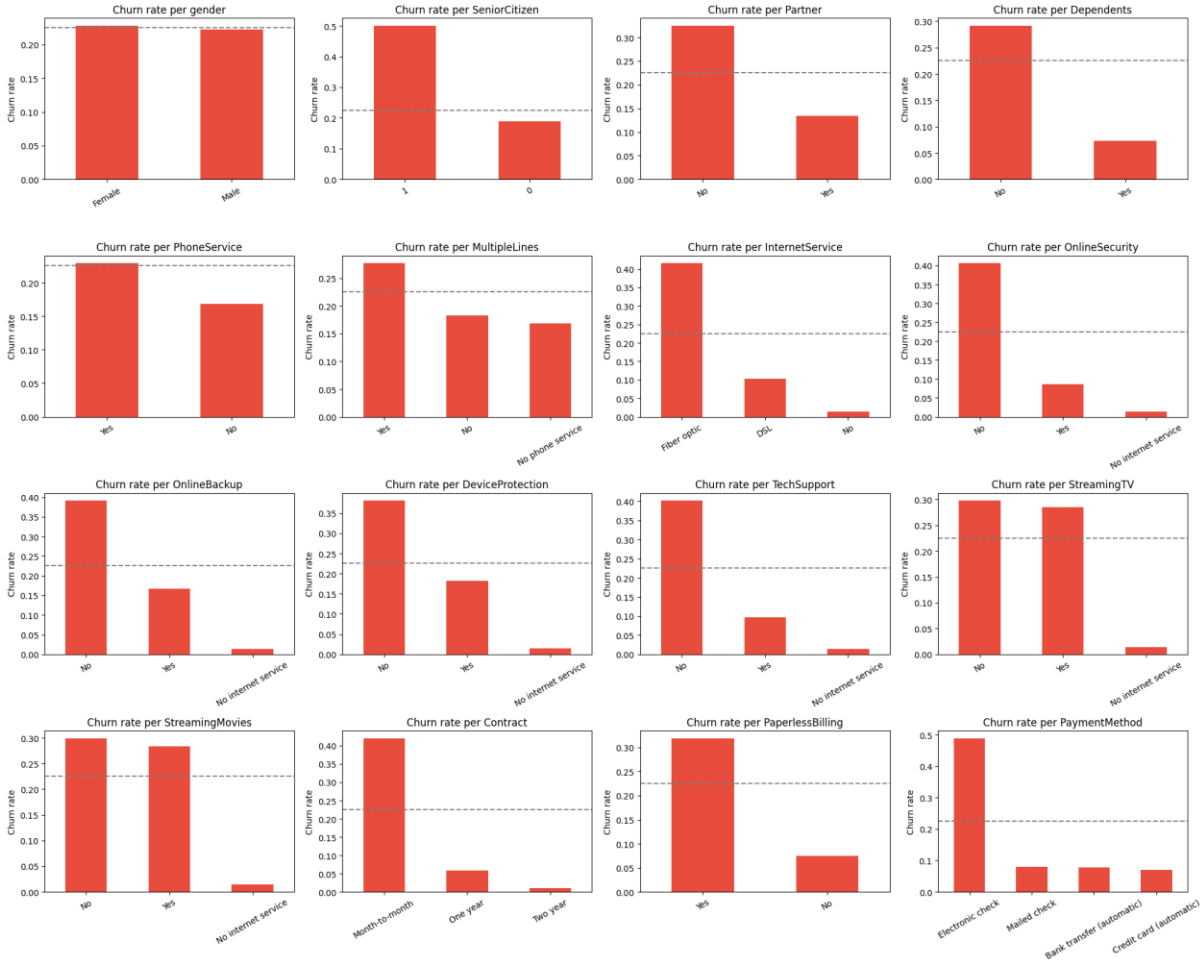


Gambar 3. Heatmap Korelasi Fitur Numerik

3.2.6 Churn Rate per Fitur Kategorikal

Tingkat churn dihitung untuk setiap kategori pada 16 fitur kategorikal dan dibandingkan dengan rata-rata keseluruhan (22,5%). Temuan utamanya adalah:

- **Contract**: Pelanggan dengan kontrak *month-to-month* memiliki tingkat churn jauh lebih tinggi dibanding kontrak satu atau dua tahun.
- **InternetService**: Pengguna *fiber optic* lebih banyak melakukan churn dibandingkan pengguna DSL maupun pelanggan tanpa internet.
- **OnlineSecurity & TechSupport**: Pelanggan yang tidak memiliki layanan ini menunjukkan tingkat churn yang lebih tinggi.
- **PaperlessBilling & PaymentMethod**: Pelanggan dengan tagihan *paperless* dan pengguna *electronic check* memiliki tingkat churn tertinggi.



Gambar 4. Churn Rate per Kategori pada Setiap Fitur Kategorikal (garis putus-putus = rata-rata)

3.3 Data Preparation

Tahap ini mengubah data mentah agar siap diproses oleh algoritma pembelajaran mesin[15]. Urutan langkah disusun untuk memastikan data uji tidak pernah digunakan dalam proses apa pun selama pelatihan:

1. **Pembersihan data**: TotalCharges dikonversi ke tipe numerik, kolom *id* dihapus, dan target Churn dikodekan menjadi 1 (Yes) dan 0 (No).
2. **Pembagian data terlebih dahulu**: Dataset dibagi menjadi data latih 80% (475.355 baris) dan data uji 20% (118.839 baris) dengan *stratified sampling*. Kedua bagian mempertahankan proporsi churn asli sebesar 22,52%.
3. **Subsampel untuk eksperimen**: Untuk efisiensi komputasi, perbandingan model dan *tuning* dilakukan pada 100.000 sampel acak terstratifikasi dari data latih. Model final tetap dilatih pada seluruh data latih.
4. **Encoding**: Fitur kategorikal dikonversi menggunakan *One-Hot Encoding* karena fitur seperti PaymentMethod tidak memiliki urutan. Pengecualian berlaku untuk CatBoost, yang mengolah fitur kategorikal secara langsung.
5. **Feature scaling**: Fitur numerik distandarisasi menggunakan StandardScaler agar Logistic Regression dapat konvergen dengan baik.

6. **Penanganan imbalance di dalam pipeline**: *Class weighting* atau SMOTE diterapkan sebagai bagian dari *pipeline*, sehingga pada setiap *fold cross-validation* teknik tersebut hanya diterapkan pada bagian data latih.
7. **Pipeline terpadu**: Seluruh langkah (*encoding*, *scaling*, penanganan *imbalance*, dan model) dibungkus dalam satu objek *pipeline* agar tidak terjadi kebocoran data dan model siap digunakan untuk *deployment*.

3.4 Modeling

Pemilihan model didasarkan pada karakteristik data: ukuran besar (594 ribu baris), dominasi fitur kategorikal (16 dari 19 fitur), ketidakseimbangan kelas (22,5% churn), adanya hubungan non-linear dan interaksi antar fitur, serta kebutuhan bisnis akan interpretabilitas.

Tabel 1. Alasan Pemilihan Model

Model	Alasan dipilih	Keterbatasan
Dummy Classifier	Batas bawah pembanding; hanya menebak berdasarkan proporsi kelas (PR-AUC ≈ 0,225).	Bukan model prediktif.
Logistic Regression	Baseline sederhana, cepat untuk data besar, koefisien mudah diinterpretasi.	Tidak menangkap interaksi antar fitur; sensitif terhadap multikolinearitas.
Decision Tree	Menghasilkan aturan *if-then* yang mudah dibaca bisnis; tidak memerlukan asumsi normalitas.	Mudah *overfitting* dan tidak stabil.
Random Forest	*Bagging* banyak pohon mengurangi *overfitting* Decision Tree; tangguh terhadap *noise*.	Model berukuran besar dan lebih lambat; umumnya di bawah *boosting*.
XGBoost	*Boosting* dengan regularisasi bawaan; salah satu algoritma terkuat untuk data tabular.	Banyak *hyperparameter* yang perlu diatur.
LightGBM	*Boosting* berbasis histogram; jauh lebih cepat dan hemat memori untuk data besar.	Rentan *overfitting* pada data kecil (tidak relevan di sini).
CatBoost	Dirancang untuk data dengan banyak fitur kategorikal; tidak memerlukan *one-hot encoding*.	Waktu pelatihan lebih lama.

Model yang tidak digunakan beserta alasannya: KNN (prediksi sangat lambat karena harus menghitung jarak ke ±475 ribu data latih), SVM (waktu pelatihan tidak praktis untuk ratusan ribu baris), Naive Bayes (asumsi independensi fitur tidak terpenuhi, misalnya tenure–TotalCharges r = 0,83), dan *Neural Network* (jarang unggul untuk data tabular serta sulit diinterpretasi).

Setiap algoritma diuji dengan tiga strategi penanganan *imbalance*: **none** (tanpa penanganan), **weight** (*class weighting*), dan **SMOTE**. SMOTE tidak diterapkan pada CatBoost (karena memerlukan input numerik) dan Dummy, sehingga total terdapat 18 konfigurasi. Setiap konfigurasi dievaluasi menggunakan *5-fold stratified cross-validation* dengan metrik utama PR-AUC. Konfigurasi terbaik kemudian dioptimasi menggunakan RandomizedSearchCV (20 kombinasi, *3-fold*).

3.5 Evaluation

Tahap evaluasi dirancang agar data uji hanya digunakan satu kali, yaitu pada pengukuran akhir:

1. **Pemilihan threshold**: *Threshold* keputusan dipilih dengan memaksimalkan F1-score pada prediksi *out-of-fold* dari data latih, bukan dari data uji.
2. **Evaluasi akhir**: Model final dilatih pada seluruh data latih lalu diukur pada data uji menggunakan PR-AUC, ROC-AUC, *precision*, *recall*, F1-score, dan *confusion matrix*. Selisih PR-AUC data latih dan data uji digunakan untuk mendeteksi *overfitting*.
3. **Cumulative gains**: Mengukur persentase pelanggan churn yang tertangkap jika perusahaan hanya menghubungi sebagian pelanggan dengan skor risiko tertinggi.
4. **Simulasi bisnis**: Mengestimasi profit program retensi berdasarkan asumsi biaya insentif dan tingkat keberhasilan retensi.
5. **Interpretasi SHAP**: Mengidentifikasi faktor yang paling memengaruhi prediksi beserta arah pengaruhnya.

BAB 4: HASIL DAN PEMBAHASAN

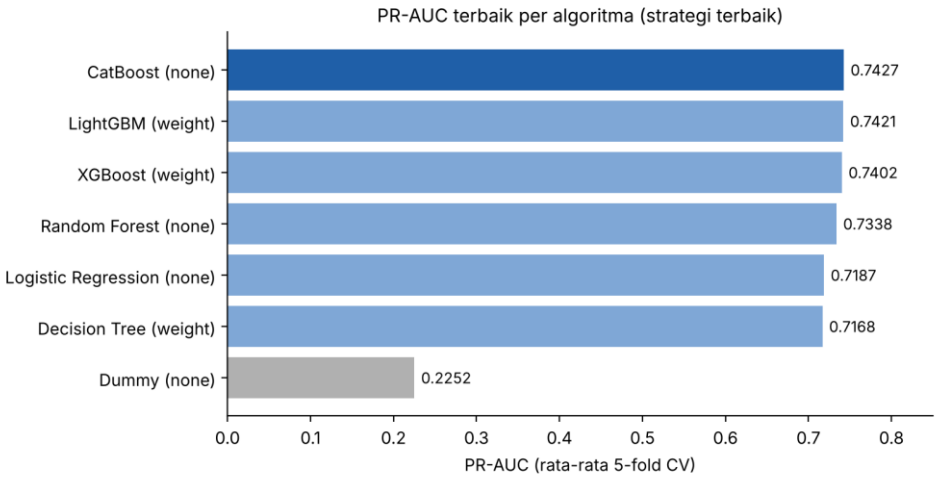
Bab ini memaparkan hasil perbandingan 18 konfigurasi model, optimasi model terbaik, evaluasi pada data uji, serta interpretasi dan dampak bisnis dari model yang dihasilkan.

4.1 Rekapitulasi Performa Seluruh Model

Tabel 2 menunjukkan hasil *5-fold cross-validation* seluruh konfigurasi, diurutkan berdasarkan PR-AUC. Kolom *Gap* adalah selisih PR-AUC antara data latih dan data validasi, yang menjadi indikator *overfitting*.

Tabel 2. Hasil 5-Fold Cross-Validation 18 Konfigurasi Model

Model	Strategi	PR-AUC	Std	ROC-AUC	Gap	Waktu fit (detik)
CatBoost	none	0,7427	0,0050	0,9122	0,0151	67,77
LightGBM	weight	0,7421	0,0053	0,9118	0,0229	1,23
CatBoost	weight	0,7419	0,0052	0,9121	0,0102	69,77
LightGBM	none	0,7418	0,0055	0,9117	0,0320	1,53
XGBoost	weight	0,7402	0,0052	0,9105	0,0558	1,19
XGBoost	none	0,7390	0,0053	0,9106	0,0647	1,29
LightGBM	smote	0,7368	0,0053	0,9099	0,0180	2,59
XGBoost	smote	0,7361	0,0043	0,9089	0,0397	3,05
Random Forest	none	0,7338	0,0053	0,9098	0,0626	3,43
Random Forest	weight	0,7322	0,0050	0,9096	0,0640	4,04
Random Forest	smote	0,7280	0,0048	0,9081	0,0800	6,66
Logistic Regression	none	0,7187	0,0040	0,9064	0,0004	0,67
Logistic Regression	smote	0,7179	0,0038	0,9062	0,0001	1,15
Logistic Regression	weight	0,7176	0,0040	0,9063	0,0003	0,79
Decision Tree	weight	0,7168	0,0058	0,9018	0,0262	0,97
Decision Tree	none	0,7157	0,0070	0,9013	0,0312	0,93
Decision Tree	smote	0,7076	0,0070	0,8995	0,0215	1,77
Dummy	none	0,2252	0,0000	0,5000	0,0000	0,32



Gambar 5. PR-AUC Terbaik per Algoritma

Beberapa temuan penting dari hasil tersebut:

- Seluruh model jauh melampaui *baseline* Dummy (PR-AUC 0,2252), sehingga model benar-benar mempelajari pola churn dari data.
- Model *boosting* (CatBoost, LightGBM, XGBoost) menempati peringkat teratas. CatBoost tanpa penanganan *imbalance* memperoleh PR-AUC tertinggi sebesar **0,7427**.
- Selisih PR-AUC antara CatBoost, LightGBM, dan XGBoost (kurang dari 0,003) lebih kecil dari standar deviasi antar *fold* (≈ 0,005), sehingga ketiganya dapat dianggap setara secara praktis. Namun, LightGBM sekitar **55 kali lebih cepat** dalam pelatihan (1,23 detik dibandingkan 67,77 detik), sehingga menjadi alternatif yang layak bila kecepatan menjadi prioritas.
- Random Forest dan XGBoost menunjukkan *gap* train–validasi yang lebih besar (0,05–0,08), menandakan kecenderungan *overfitting* yang lebih tinggi dibanding CatBoost (0,0151).
- Logistic Regression hampir tidak memiliki *gap* (≤ 0,0004) dan mencapai PR-AUC 0,7187, menunjukkan bahwa sebagian besar pola churn sudah dapat ditangkap oleh hubungan linear sederhana.

4.2 Dampak Strategi Penanganan Imbalance

Tabel 3. PR-AUC per Strategi Penanganan Imbalance

Model	none	weight	SMOTE
Logistic Regression	0,7187	0,7176	0,7179
Decision Tree	0,7157	0,7168	0,7076
Random Forest	0,7338	0,7322	0,7280
XGBoost	0,7390	0,7402	0,7361
LightGBM	0,7418	0,7421	0,7368
CatBoost	0,7427	0,7419	–

SMOTE tidak pernah menjadi strategi terbaik pada model mana pun. Ketika diterapkan dengan benar (hanya pada data latih di dalam *pipeline*), SMOTE justru sedikit menurunkan PR-AUC dibanding tanpa penanganan atau *class weighting*. Strategi *weight* memang meningkatkan *recall* pada *threshold* default 0,5 (contohnya LightGBM dari 0,638 menjadi 0,869), tetapi dengan menurunkan *precision*. Efek yang sama dapat dicapai melalui pengaturan *threshold* tanpa mengubah kemampuan model dalam mengurutkan risiko. Hal ini menjelaskan mengapa PR-AUC antar strategi hampir sama.

4.3 Hyperparameter Tuning

Konfigurasi terbaik (CatBoost, *none*) dioptimasi menggunakan RandomizedSearchCV dengan 20 kombinasi dan *3-fold cross-validation* (60 kali pelatihan). Parameter terbaik yang diperoleh adalah *learning_rate* = 0,05, *depth* = 6, *l2_leaf_reg* = 5, dan *iterations* = 800, dengan PR-AUC validasi **0,7427**. Nilai ini sama dengan konfigurasi awal, sehingga dapat disimpulkan bahwa pengaturan default CatBoost sudah mendekati optimal untuk dataset ini dan peningkatan performa lebih lanjut kemungkinan besar perlu dicapai melalui rekayasa fitur, bukan *tuning*.

4.4 Performa Model Terbaik pada Data Uji

Model final dilatih pada seluruh data latih (475.355 baris) dan dievaluasi pada data uji (118.839 baris) yang mempertahankan distribusi kelas asli (22,5% churn):

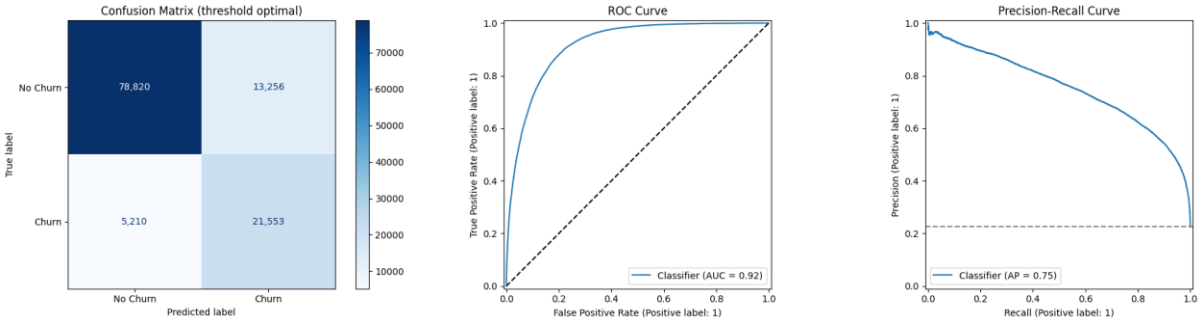
- **PR-AUC test: 0,7544**, atau 3,35 kali lebih baik dibanding model acak (0,2252).
- **ROC-AUC test: 0,9164**, yang termasuk kategori *excellent* (di atas 0,90)[12].
- PR-AUC data latih 0,7578 dibandingkan data uji 0,7544 (selisih 0,0034), sehingga **model tidak mengalami overfitting**.

Threshold optimal yang dipilih dari prediksi *out-of-fold* data latih adalah **0,33**. Tabel 4 membandingkan performa pada *threshold* default 0,5 dan *threshold* optimal.

Tabel 4. Performa Kelas Churn pada Dua Threshold (Data Uji)

Metrik	Threshold 0,5	Threshold 0,33
Precision (Churn)	0,7119	0,6192
Recall (Churn)	0,6411	0,8053
F1-score (Churn)	0,6746	0,7001
Accuracy	0,8608	0,8446
Macro F1	0,7930	0,7976

Dengan *threshold* 0,33, model menangkap **80,5% pelanggan yang benar-benar churn**, dan sekitar 6 dari 10 pelanggan yang ditandai berisiko memang melakukan churn. Penurunan *accuracy* dari 86,1% menjadi 84,5% dapat diterima karena dalam konteks retensi, kehilangan pelanggan yang tidak terdeteksi umumnya lebih mahal daripada memberikan insentif kepada pelanggan yang sebenarnya tidak berniat pergi.



Gambar 6. Confusion Matrix (threshold 0,33), ROC Curve, dan Precision-Recall Curve pada Data Uji

4.4.1 Analisis Confusion Matrix

Hasil prediksi pada data uji (118.839 pelanggan) dengan *threshold* 0,33 adalah sebagai berikut:

- **True Negative (TN): 78.820**, yaitu pelanggan yang bertahan dan diprediksi bertahan.
- **True Positive (TP): 21.553**, yaitu pelanggan churn yang berhasil terdeteksi.
- **False Negative (FN): 5.210**, yaitu pelanggan churn yang gagal terdeteksi.
- **False Positive (FP): 13.256**, yaitu pelanggan yang bertahan namun diprediksi churn.

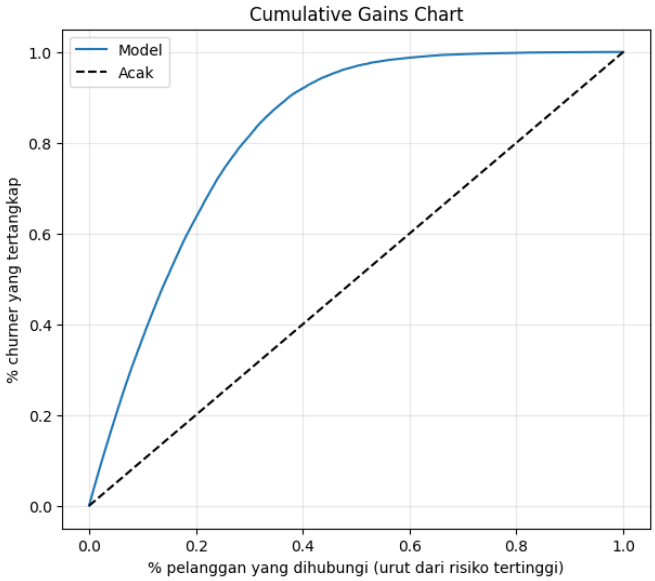
Dari 26.763 pelanggan yang benar-benar churn, hanya 5.210 (19,5%) yang terlewat. Jumlah *false positive* yang lebih besar merupakan konsekuensi yang disengaja dari pemilihan *threshold* rendah. Bagi bisnis, kesalahan ini berarti sebagian insentif retensi diberikan kepada pelanggan yang sebenarnya tidak berniat pergi.

4.5 Efektivitas Penargetan (Cumulative Gains)

Pelanggan pada data uji diurutkan dari skor risiko tertinggi, lalu dihitung persentase pelanggan churn yang tertangkap pada setiap persentase pelanggan yang dihubungi.

Tabel 5. Cumulative Gains pada Data Uji

Pelanggan yang dihubungi	Churner yang tertangkap	Lift
Top 10% risiko	36,9%	3,69×
Top 20% risiko	63,5%	3,17×
Top 30% risiko	81,5%	2,72×

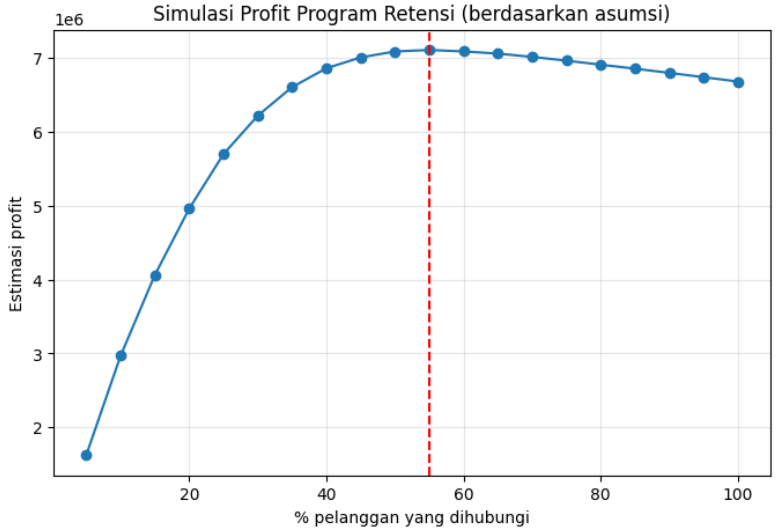


Gambar 7. Cumulative Gains Chart

Dengan hanya menghubungi 20% pelanggan berisiko tertinggi, perusahaan dapat menjangkau hampir dua pertiga (63,5%) dari seluruh pelanggan yang akan churn, atau 3,17 kali lebih efektif dibanding pemilihan pelanggan secara acak.

4.6 Simulasi Dampak Bisnis

Simulasi profit program retensi dilakukan pada data uji dengan asumsi: biaya insentif 10 unit mata uang per pelanggan yang dihubungi, tingkat keberhasilan retensi 30%, dan pendapatan yang terselamatkan dihitung selama 12 bulan (MonthlyCharges × 12). Asumsi ini bersifat ilustratif dan perlu disesuaikan dengan data biaya aktual perusahaan.

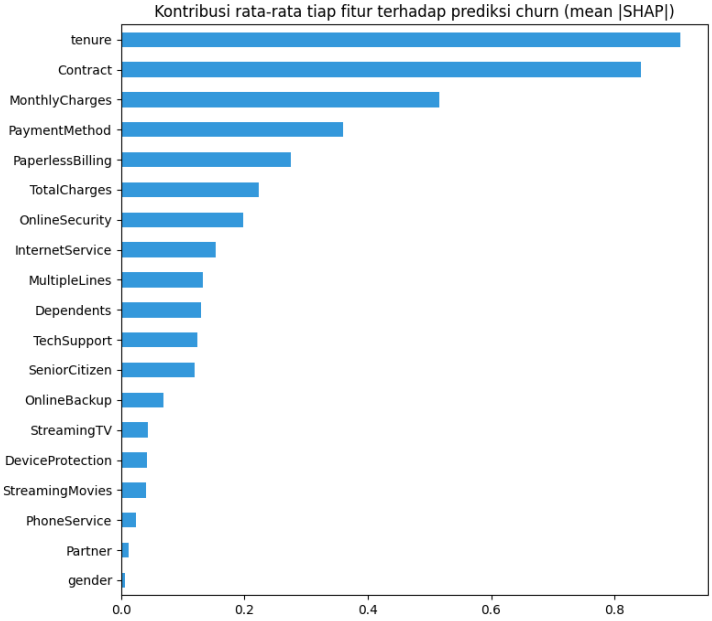


Gambar 8. Simulasi Profit Program Retensi berdasarkan Persentase Pelanggan yang Dihubungi

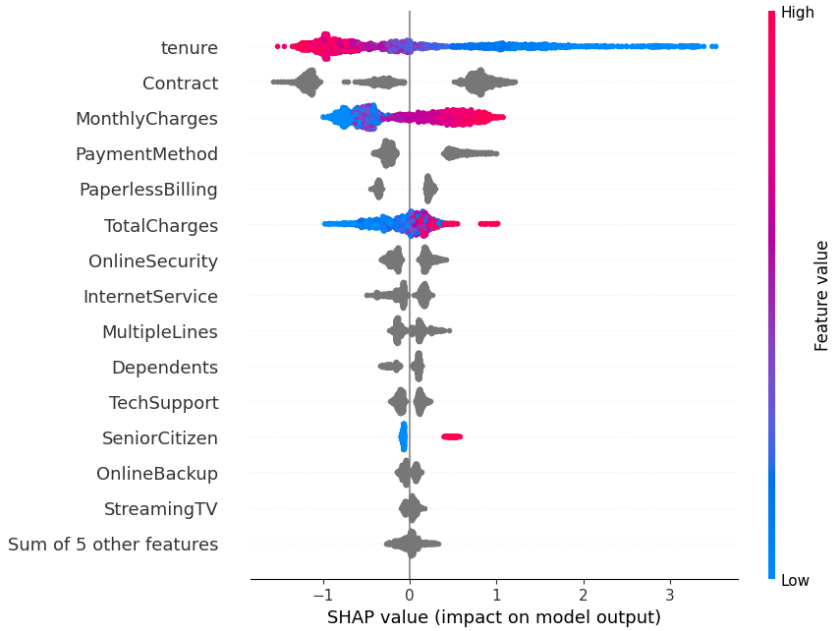
Profit maksimum (≈ 7,1 juta unit mata uang pada data uji) dicapai saat menghubungi **top 55%** pelanggan berisiko. Kurva profit relatif datar pada rentang 45–70%, sehingga menargetkan sekitar 45% pelanggan sudah memberikan profit yang hampir sama dengan jumlah kontak yang lebih sedikit. Hasil ini sangat bergantung pada asumsi: semakin mahal biaya insentif, semakin kecil proporsi pelanggan yang optimal untuk dihubungi.

4.7 Faktor Penyebab Churn (SHAP)

Interpretasi model dilakukan menggunakan SHAP pada 2.000 sampel data uji. Gambar 9 menunjukkan tingkat kepentingan global setiap fitur, sedangkan Gambar 10 menunjukkan sebaran pengaruh setiap fitur terhadap prediksi.



Gambar 9. Kontribusi Rata-rata Setiap Fitur terhadap Prediksi Churn (mean |SHAP|)



Gambar 10. SHAP Beeswarm Plot (warna hanya tersedia untuk fitur numerik)

Karena CatBoost mengolah fitur kategorikal sebagai teks, arah pengaruh setiap kategori dihitung dari rata-rata nilai SHAP per kategori (Tabel 6). Nilai positif berarti menaikkan risiko churn.

Tabel 6. Rata-rata Nilai SHAP per Kategori

Fitur	Kategori yang menaikkan risiko	Kategori yang menurunkan risiko
Contract	Month-to-month (+0,817)	One year (−0,316); Two year (−1,180)
PaymentMethod	Electronic check (+0,541)	Credit card otomatis (−0,251); Bank transfer otomatis (−0,259); Mailed check (−0,261)
PaperlessBilling	Yes (+0,224)	No (−0,365)
OnlineSecurity	No (+0,206)	Yes (−0,215); No internet service (−0,161)
InternetService	Fiber optic (+0,159)	DSL (−0,190); No (−0,093)
TechSupport	No (+0,127)	Yes (−0,131); No internet service (−0,105)

Interpretasi hasil SHAP:

- **tenure** adalah faktor paling berpengaruh. Pelanggan baru (tenure rendah) memiliki risiko churn jauh lebih tinggi, sedangkan pelanggan lama cenderung bertahan.
- **Contract** adalah faktor kedua terbesar. Kontrak *month-to-month* menaikkan risiko, sedangkan kontrak dua tahun menjadi faktor pelindung terkuat (−1,180).
- **MonthlyCharges**: tagihan bulanan yang tinggi meningkatkan risiko churn.
- **PaymentMethod**: *electronic check* adalah satu-satunya metode pembayaran yang menaikkan risiko; ketiga metode lainnya menurunkan risiko dengan besaran yang hampir sama.
- **SeniorCitizen**: pelanggan lansia memiliki risiko churn lebih tinggi.
- **gender**, **Partner**, dan **PhoneService** hampir tidak berpengaruh terhadap prediksi.

Profil pelanggan dengan risiko tertinggi adalah pelanggan baru dengan kontrak bulanan, pembayaran via *electronic check*, *paperless billing*, menggunakan *fiber optic*, dan tidak berlangganan Online Security maupun Tech Support. Temuan ini **konsisten dengan analisis churn rate per kategori** pada tahap Data Understanding (Subbab 3.2.6), sehingga memperkuat validitas model.

4.8 Perbandingan dengan Pendekatan Sebelumnya

Versi awal penelitian ini menerapkan SMOTE pada seluruh dataset **sebelum** pembagian data latih dan uji. Akibatnya, data uji berisi sampel sintetis yang dibentuk dari tetangga di data latih, dan distribusinya menjadi 50:50 sehingga tidak mencerminkan kondisi nyata. Tabel 7 merangkum perbedaan kedua pendekatan.

Tabel 7. Perbandingan Pendekatan Awal dan Pendekatan Revisi

Aspek	Pendekatan awal	Pendekatan revisi
Urutan SMOTE	Sebelum *split* (kebocoran data)	Di dalam *pipeline*, hanya pada data latih
Distribusi data uji	50% : 50% (sintetis)	77,5% : 22,5% (asli)
Encoding kategorikal	Label Encoding	One-Hot Encoding / native CatBoost
Jumlah model	5 algoritma	6 algoritma + Dummy, 3 strategi *imbalance*
Metrik utama	Accuracy	PR-AUC

Aspek	Pendekatan awal	Pendekatan revisi
Tuning	GridSearchCV (*scoring*: accuracy)	RandomizedSearchCV (*scoring*: PR-AUC)
Threshold	Default 0,5	Dipilih dari *out-of-fold* data latih (0,33)
Model terbaik	Random Forest GridSearchCV	CatBoost
Accuracy (threshold 0,5)	88,88%	86,08%
ROC-AUC	0,9551	0,9164
Interpretasi & dampak bisnis	Tidak ada	SHAP, *cumulative gains*, simulasi profit

Angka pada pendekatan awal terlalu optimis karena dipengaruhi kebocoran data. Pendekatan revisi menghasilkan angka yang lebih rendah, tetapi merupakan estimasi yang jujur terhadap performa model pada pelanggan baru yang belum pernah dilihat model.

BAB 5: KESIMPULAN DAN REKOMENDASI

5.1 Kesimpulan

Berdasarkan seluruh rangkaian penelitian, mulai dari eksplorasi data hingga evaluasi model pada data uji, dapat ditarik kesimpulan sebagai berikut:

1. **Faktor pendorong churn (Rumusan Masalah 1)**: Faktor paling berpengaruh adalah masa berlangganan (tenure), jenis kontrak (Contract), dan tagihan bulanan (MonthlyCharges), diikuti metode pembayaran dan *paperless billing*. Risiko tertinggi dimiliki pelanggan baru dengan kontrak bulanan yang membayar menggunakan *electronic check*, sedangkan kontrak dua tahun menjadi faktor pelindung terkuat.
2. **Performa komparatif algoritma (Rumusan Masalah 2)**: Model *boosting* unggul dibanding model lainnya. CatBoost memperoleh PR-AUC validasi tertinggi (0,7427), diikuti sangat dekat oleh LightGBM (0,7421) dan XGBoost (0,7402). Pada data uji, model CatBoost final mencapai PR-AUC 0,7544 dan ROC-AUC 0,9164 tanpa indikasi *overfitting* (selisih train–test 0,0034).
3. **Penanganan imbalance dan tuning (Rumusan Masalah 3)**: SMOTE tidak pernah menjadi strategi terbaik. Ketidakseimbangan kelas lebih efektif ditangani melalui pemilihan *threshold* (0,33), yang meningkatkan *recall* kelas churn dari 64,1% menjadi 80,5%. *Hyperparameter tuning* tidak memberikan peningkatan berarti, menunjukkan bahwa pengaturan default CatBoost sudah mendekati optimal.
4. **Nilai bisnis (Rumusan Masalah 4)**: Dengan menghubungi 20% pelanggan berisiko tertinggi, perusahaan dapat menjangkau 63,5% pelanggan yang akan churn (*lift* 3,17×). Berdasarkan asumsi simulasi, program retensi paling menguntungkan dijalankan pada sekitar 45–55% pelanggan berisiko tertinggi.
5. **Pentingnya protokol evaluasi**: Koreksi kebocoran data menurunkan *accuracy* dari 88,88% menjadi 86,08%. Penurunan ini bukan berarti model memburuk, melainkan angka sebelumnya tidak mencerminkan performa nyata.

5.2 Rekomendasi

1. Implementasi Bisnis (Strategi Retensi)

- **Dorong migrasi ke kontrak jangka panjang**: berikan diskon atau bonus bagi pelanggan *month-to-month* yang beralih ke kontrak satu atau dua tahun.
- **Program onboarding pelanggan baru**: lakukan pemantauan proaktif pada bulan-bulan awal berlangganan, misalnya melalui *follow-up* dan survei kepuasan pada bulan pertama dan ketiga.
- **Dorong pembayaran otomatis**: berikan insentif kecil bagi pengguna *electronic check* yang beralih ke autodebet kartu kredit atau rekening bank.
- **Bundel layanan tambahan**: tawarkan Online Security dan Tech Support (misalnya gratis tiga bulan) kepada pelanggan berisiko.
- **Evaluasi segmen fiber optic**: kaji harga dan kualitas layanan pada segmen ini, terutama pelanggan dengan tagihan bulanan tinggi.
- **Gunakan skor risiko model** untuk mengurutkan prioritas kontak tim retensi.

2. Pengembangan Teknis

- **Rekayasa fitur**: karena *tuning* tidak lagi meningkatkan performa, peningkatan berikutnya sebaiknya dicari melalui fitur baru, misalnya rata-rata tagihan per bulan (TotalCharges/tenure) atau jumlah layanan tambahan yang digunakan.
- **Validasi pada data asli perusahaan**: dataset yang digunakan berasal dari kompetisi Kaggle Playground Series, sehingga model perlu divalidasi ulang pada data pelanggan nyata sebelum digunakan.
- **Pertimbangan model produksi**: LightGBM dapat menjadi alternatif CatBoost di lingkungan produksi karena performanya setara namun waktu pelatihannya jauh lebih cepat.
- **Simulasi dengan biaya aktual**: parameter simulasi bisnis (biaya insentif dan tingkat keberhasilan retensi) perlu diganti dengan data aktual perusahaan.
- **Integrasi sentimen**: melakukan analisis ulasan pelanggan di platform digital menggunakan *Natural Language Processing* (NLP) untuk memperoleh wawasan kualitatif mengenai alasan pelanggan melakukan churn[13,16].

REFERENSI

1. Wakhidah, L. N., Khanif Zyen, A. & Wahono, B. B. Evaluation of Telecommunication Customer Churn Classification with SMOTE Using Random Forest and XGBoost Algorithms. Journal of Applied Informatics and Computing (JAIC) vol. 9 http://jurnal.polibatam.ac.id/index.php/JAIC (2025).
2. Arina, F. & Ulfah, M. Analisa survival untuk mengurangi customer churn pada perusahaan telekomunikasi. Journal Industrial Servicess 8, 59 (2022).
3. Prakoso, A. et al. Prediksi Churn Pelanggan Telekomunikasi Menggunakan Metode Supervised Learning dengan Random Forest dan XGBoost. Jurnal Pengabdian Masyarakat dan Riset Pendidikan 4, 17661–17667 (2026).
4. Agian, N., Dinata, S., Abdurrahman, G. & Fitriyah, N. Q. Perbandingan Optimasi Algoritma Random Forest Menggunakan Teknik Boosting Terhadap Kasus Klasifikasi Churn Pelanggan Di Industri Telekomunikasi. www.kaggle.com.
5. Antoh, S., Herteno, R., Budiman, I., Kartini, D. & Mazdadi, M. I. Prediksi Churn Pelanggan Telekomunikasi dengan Optimalisasi Seleksi Fitur dan Tuning Hyperparameter pada Algoritma Klasifikasi C4.5. Jurnal Sistem Informasi Bisnis 15, 60–67 (2025).
6. Andy Hermawan et al. Membangun Model Prediksi Churn Pelanggan yang Akurat. Merkurius: Jurnal Riset Sistem Informasi dan Teknik Informatika 2, 67–81 (2024).
7. Rianti, A. et al. CRISP-DM: Metodologi Proyek Data Science.
8. Fauzan, R., Vitianingsih, A. V., Cahyono, D., Maukar, A. L. & Suprio, Y. A. B. Penerapan Algoritma Klasifikasi pada Machine Learning untuk Deteksi Phishing. MALCOM: Indonesian Journal of Machine Learning and Computer Science 5, 531–540 (2025).
9. Syarief Albani, M., Kurniawan, D. & Ditha Tania, K. Komparasi Model Ensemble dan Algoritma Machine Learning Untuk Memprediksi Penyakit Jantung. Technology and Science (BITS) 7, (2026).
10. Rearizth Muhammad Daffaa, Deris Santika & Fathoni Mahardika. Perbandingan Xgboost dan Logistic Regression dalam Memprediksi Credit Card Customer Churn. Jupiter: Publikasi Ilmu Keteknikan Industri, Teknik Elektro dan Informatika 3, 07–21 (2025).
11. 1-12+Klasifikasi+Customer+Churn+Menggunakan+XGBoost+dengan+Optimasi+GridSearchCV+Berbasis+Shapley+Additive+Explanations.
12. Sijabat, G. F., Aji, W. & Prabowo, E. Studi Komparatif Model Machine Learning untuk Klasifikasi Penyakit Jantung dengan SMOTE pada Data Imbalanced. Jurnal Riset Komputer 13, 2407–389 (2026).
13. Riza, F., Febrianto Hendrakusuma, D., Wibowo, B., Yusuf Al Afghani, D. & Teknologi Budi Utomo, I. Comparison of Machine Learning Classification Algorithm Performance in Wondr by BNI Mobile Banking Review Sentiment Analysis. Journal of Information Technology and Computer Science (INTECOMS) 8, (2025).

14. Surya Budiman, A. Uji Akurasi Algoritma Machine Learning Untuk Pemodelan Prediksi Faktor Pendorong Pergantian Karyawan. JSI: Jurnal Sistem Informasi (E-Journal) 15, (2023).
15. Herdian, C., Kamila, A. & Agung Musa Budidarma, I. G. Studi Kasus Feature Engineering Untuk Data Teks: Perbandingan Label Encoding dan One-Hot Encoding Pada Metode Linear Regresi. Technologia: Jurnal Ilmiah 15, 93 (2024).
16. Utami, F. N., Dewi Ariessanti, H., Widayanti, R. & Ichwani, A. Klasifikasi Sentimen untuk Prediksi Churn Pengguna Aplikasi Mamikos Menggunakan Support Vector Machine (SVM) dan Naïve Bayes. https://doi.org/10.38035/jim.v4i4.
17. Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V. & Gulin, A. CatBoost: unbiased boosting with categorical features. Advances in Neural Information Processing Systems 31 (2018).
18. Chawla, N. V., Bowyer, K. W., Hall, L. O. & Kegelmeyer, W. P. SMOTE: Synthetic Minority Over-sampling Technique. Journal of Artificial Intelligence Research 16, 321–357 (2002).
19. Bergstra, J. & Bengio, Y. Random Search for Hyper-Parameter Optimization. Journal of Machine Learning Research 13, 281–305 (2012).
20. Saito, T. & Rehmsmeier, M. The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets. PLoS ONE 10, e0118432 (2015).
21. Lundberg, S. M. & Lee, S.-I. A Unified Approach to Interpreting Model Predictions. Advances in Neural Information Processing Systems 30 (2017).

LAMPIRAN

Tabel 8. Pembagian Peran Anggota Kelompok

Nama	NIM	Peran	Kontribusi Utama
Andree Hayden Fernando	00000112246	Project Lead	Koordinasi proyek, arsitektur pipeline, dan integrasi hasil akhir.
Frans Marco Haryanto	00000108659	Model Developer	Implementasi algoritma serta tuning hyperparameter.
Kenzie Tristan Tang	00000110240	Presenter	Penyusunan laporan, visualisasi hasil, dan interpretasi model.
Kingsty James Wayne	00000110615	Data Analyst	Eksplorasi data (EDA), pembersihan data, dan penanganan ketidakseimbangan kelas.

Dataset: Telco Customer Churn Dataset. Kaggle Playground Series. Diakses melalui: https://www.kaggle.com/competitions/playground-series-s6e3

Kode sumber: UAS_Datmod_Kel5.ipynb (Python: pandas, scikit-learn, imbalanced-learn, XGBoost, LightGBM, CatBoost, SHAP).